



UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE - UFRN
CENTRO DE ENSINO SUPERIOR DO SERIDÓ - CERES
DEPARTAMENTO DE COMPUTAÇÃO E TECNOLOGIA DCT



ARIADNY FRANCISCA DANTAS SANTOS

TÓPICOS AVANÇADOS DE INTELIGÊNCIA ARTIFICIAL A

ARIADNY FRANCISCA DANTAS SANTOS

TÓPICOS AVANÇADOS DE INTELIGÊNCIA ARTIFICIAL A

Relatório de atividades apresentado como requisito para obtenção de nota na disciplina **Tópicos Avançados de Inteligência Artificial A**, ofertada pela UFRN no período letivo 2026.1.

Professor: Prof. Dr. Thommas K. S. Flores

Universidade Federal do Rio Grande do Norte - UFRN
Centro de Ensino Superior do Seridó - CERES
Departamento de Computação e Tecnologia - DCT

Caicó - RN
2026

Índice

1	Introdução	4
2	Análise Exploratória de Dados (EDA)	4
2.1	Integração e Inspeção Inicial	4
2.2	Identificação de Valores Ausentes	4
2.3	Deteção e Análise de Outliers	5
2.3.1	Idade do Cliente (Customer_Age):	5
2.3.2	Custo de Frete (Shipping_Cost):	6
2.3.3	Quantidade (Quantity):	6
2.3.4	Preço de Venda (Selling_Price):	7
2.3.5	Valor total final da compra	8
2.4	Análise de Correlação e Multicolinearidade	8
3	Limpeza e Pré-processamento	10
3.1	Tratamento de Valores Ausentes	10
3.2	Tratamento de Outliers	10
3.3	Resolução de Multicolinearidade	10
3.4	Codificação e Padronização	11
4	Percepções para Regressão e Classificação	11
4.1	Problema de Regressão	11
4.2	Problema de Classificação	12
5	Considerações Finais	13
6	Referência ao Repósitorio	14

Lista de Figuras

1	Detecção de Outliers: Idade do Cliente	5
2	Detecção de Outliers: Custo de Frete	6
3	Detecção de Outliers: Quantidade	6
4	Detecção de Outliers: Preço de Venda	7
5	Detecção de Outliers: Valor total da compra	8
6	Mapa de calor da matriz de correlação das variáveis numéricas.	9

1 Introdução

Este relatório tem como objetivo documentar as etapas de Análise Exploratória de Dados (EDA) e pré-processamento realizadas como requisito prático da disciplina DCT1401 - Inteligência Artificial. O foco principal do trabalho é estruturar, limpar e transformar um conjunto de dados bruto para que ele possa ser consumido com eficiência por algoritmos de *Machine Learning*, viabilizando a modelagem preditiva para dois problemas distintos: um de regressão e outro de classificação.

O *dataset* em estudo representa o banco de dados de um comércio eletrônico (e-commerce) resultante da união de tabelas de clientes e pedidos. Ele é composto por uma riqueza de variáveis demográficas (como a idade do consumidor), características do catálogo de produtos (como categorias e preço original) e métricas financeiras transacionais (como custo de frete, descontos aplicados e valor total da compra). Compreender o comportamento dessa base, isolar anomalias e identificar relações de multicolinearidade entre os atributos financeiros são passos fundamentais para garantir a precisão e a estabilidade dos modelos preditivos que serão construídos nas fases seguintes.

2 Análise Exploratória de Dados (EDA)

2.1 Integração e Inspeção Inicial

A primeira etapa da análise consistiu na unificação dos três conjuntos de dados originais (clientes, produtos e pedidos) por meio de chaves primárias e estrangeiras. Essa consolidação permitiu a criação de um *dataset* único e abrangente, viabilizando o cruzamento de informações demográficas, financeiras e comportamentais para as etapas subsequentes.

2.2 Identificação de Valores Ausentes

Após a inspeção estrutural, constatou-se que as únicas variáveis que apresentam valores nulos significativos são o Código de Cupom (*Coupon_Code*), a Avaliação Numérica (*Rating*) e o Texto da Avaliação (*Review_Text*).

A baixa incidência de dados na coluna de cupons é justificada pelas próprias regras de negócio, uma vez que a distribuição promocional é restrita a uma parcela pequena de clientes. Da mesma forma, as métricas de avaliação sofrem com a abstenção natural dos consumidores, visto que o *feedback* pós-compra não é uma etapa obrigatória. Em termos de impacto na modelagem, essas ausências não representam erros de coleta estrutural. Contudo, apesar da alta taxa de nulidade, a manutenção e o tratamento dessas variáveis são estrategicamente importantes para futuras análises de satisfação do consumidor.

2.3 Detecção e Análise de Outliers

A identificação de valores atípicos (*outliers*) nas variáveis numéricas foi realizada utilizando o método estatístico do Intervalo Interquartil (IQR) aliado à visualização por gráficos de caixa (*boxplots*). A análise revelou os seguintes comportamentos:

2.3.1 Idade do Cliente (Customer_Age):




Figura 1: Detecção de Outliers: Idade do Cliente

A grande maioria dos clientes concentra-se entre 25 e 43 anos, com o limite matemático superior estabelecido em 68 anos. Os *outliers* detectados referem-se a idades entre 69 e 75 anos. Trata-se de uma variação demográfica natural (clientes idosos reais, que representam uma minoria estatística), sem indícios de erros de digitação.

2.3.2 Custo de Frete (Shipping_Cost):



Figura 2: Detecção de Outliers: Custo de Frete

A distribuição dos dados encontra-se esmagada no eixo zero, indicando uma forte política de "Frete Grátis" para a esmagadora maioria dos pedidos. Os *outliers* densos observados (valores entre 50 e 90) representam exceções reais, possivelmente associadas a entregas expressas, internacionais ou para regiões remotas.

2.3.3 Quantidade (Quantity):




Figura 3: Detecção de Outliers: Quantidade

O comportamento padrão absoluto da base é a compra de apenas uma (1) unidade por pedido. Valores atípicos marcados em 2 e 3 unidades são ocorrências estatisticamente raras, mas legítimas, refletindo pequenas compras em atacado.

2.3.4 Preço de Venda (Selling_Price):




Figura 4: Detecção de Outliers: Preço de Venda

Com a maioria dos produtos custando até 25.000, notou-se uma longa cauda de *outliers* alcançando até 140.000. Essa dispersão não indica anomalias de sistema, mas sim a característica de um catálogo diverso, que engloba desde itens cotidianos até uma linha de produtos *premium* ou de alto luxo.

2.3.5 Valor total final da compra




Figura 5: Detecção de Outliers: Valor total da compra

O comportamento espelha a variável de preço de venda, apresentando picos que chegam a ultrapassar a marca de 400.000. Isso ocorre pelo efeito cascata: a aquisição de múltiplas unidades de um produto de alto valor agregado eleva exponencialmente o valor final do carrinho, refletindo, possivelmente, expressivas negociações corporativas (B2B).

2.4 Análise de Correlação e Multicolinearidade

Para compreender a relação linear entre os atributos numéricos contínuos, foi gerada uma matriz de correlação, visualizada através de um mapa de calor (*heatmap*).




Figura 6: Mapa de calor da matriz de correlação das variáveis numéricas.

A análise da Figura 6 destaca uma correlação altamente positiva (0.88) entre as variáveis *Total_Amount* e *Selling_Price*. Essa relação é esperada pela lógica de negócio, visto que o valor total é diretamente derivado do preço de venda somado a taxas adicionais.

Entudo, sob a ótica de *Machine Learning*, esse cenário configura um caso clássico de **multicolinearidade**, que acarreta severas implicações metodológicas:

- **Redundância e Instabilidade:** Fornecer ambas as variáveis ao algoritmo gera redundância. Em modelos estatísticos tradicionais (como regressões lineares), o algoritmo sofre confusão ao tentar atribuir pesos de importância isolados para atributos quase idênticos, resultando em cálculos instáveis e na perda da capacidade explicativa do modelo.
- **Vazamento de Dados (*Data Leakage*):** Caso o objetivo preditivo seja estimar o *Total_Amount*, a manutenção do *Selling_Price* entre as variáveis preditoras causará um vazamento de informação. O modelo apresentará falsas métricas de alta acurácia não por aprendizado real, mas por ter recebido antecipadamente a "resposta" majoritária da predição.

Diante disso, a estratégia a ser adotada na fase de pré-processamento exigirá a remoção estratégica de uma destas variáveis, a depender da definição da variável-alvo (*target*) para os problemas de regressão e classificação.

3 Limpeza e Pré-processamento

3.1 Tratamento de Valores Ausentes

A análise exploratória revelou a presença de valores nulos concentrados nas variáveis de Código de Cupom (*Coupon_Code*), Avaliação Numérica (*Rating*) e Texto da Avaliação (*Review_Text*).

A estratégia clássica de imputação pela média ou mediana foi descartada, pois induziria o modelo preditivo a erros conceituais: não se deve atribuir uma nota mediana a um cliente que optou por não avaliar um produto, nem presumir o uso de cupons onde não houve. A ausência, neste contexto, é uma informação valiosa em si.

Portanto, a estratégia de imputação adotada foi o preenchimento por valores constantes indicativos:

- **Coupon_Code e Review_Text:** Valores nulos foram substituídos pelas *strings* de marcação “Sem_Cupom” e “Sem_Avaliacao”.
- **Rating:** A variável foi convertida para o formato categórico e seus valores nulos foram substituídos pela *string* de marcação “Sem_Avaliacao”. Essa conversão permite que a ausência de nota se torne uma categoria independente válida, preservando a integridade estatística das notas reais (1 a 5) concedidas pelos demais clientes sem rebaixar artificialmente a média de avaliação dos produtos.

3.2 Tratamento de Outliers

Apesar da detecção de expressivos valores atípicos em variáveis como *Total_Amount*, *Selling_Price*, *Quantity* e *Shipping_Cost*, a decisão metodológica adotada foi a **manutenção integral dos outliers** na base de dados.

A justificativa baseia-se na origem orgânica e legítima desses dados. A exclusão ou transformação logarítmica dessas entradas ocultaria do modelo de *Machine Learning* comportamentos cruciais do negócio, tais como vendas corporativas em alto volume (B2B), aquisições de produtos da linha de luxo e a maciça política de frete grátis da plataforma. Preservar essas informações garante que os modelos futuros sejam robustos e capazes de generalizar previsões para clientes de alto valor agregado (VIPs).

3.3 Resolução de Multicolinearidade

Conforme identificado na etapa de correlação, as variáveis *Total_Amount* e *Selling_Price* apresentaram alta redundância informacional. Para mitigar o risco de instabilidade matemática e vazamento de dados (*data leakage*) nos algoritmos de *Machine Learning*, optou-se pela exclusão (remoção de coluna) da variável *Selling_Price* do *dataset*, mantendo o Valor Total da Compra como o indicador financeiro principal.

3.4 Codificação e Padronização

Para adequar a base aos requisitos estritos dos algoritmos preditivos, foram aplicadas as seguintes técnicas estruturais finais:

- **Codificação Categórica:** Variáveis nominais como *Payment_Mode*, *Category* e *Gender* foram submetidas ao método *One-Hot Encoding* (via *get_dummies* do Pandas), convertendo classes textuais em colunas binárias independentes sem assumir ordem hierárquica.
- **Padronização Numérica:** Variáveis contínuas de grandezas muito distintas (ex: Idades vs. Montantes Financeiros na casa dos milhares) foram submetidas ao *StandardScaler* (Z-score). Essa técnica centraliza a média em zero e ajusta o desvio padrão para 1, evitando que algoritmos sensíveis à distância (como KNN ou SVM) atribuam pesos desproporcionais às variáveis de maior magnitude.

4 Percepções para Regressão e Classificação

4.1 Problema de Regressão

Identificação da Variável Alvo (Target): A variável contínua selecionada como alvo para a regressão foi o *Total_Amount* (Valor Total da Compra).

Justificativa: No domínio do comércio eletrônico, prever o montante financeiro final de um carrinho de compras é essencial para projeções de receita e gestão de fluxo de caixa. A variável apresenta alta variabilidade contínua (ampla distribuição de valores) e correlaciona-se diretamente com as políticas de precificação e o comportamento de consumo, tornando-a a candidata ideal tanto matematicamente quanto do ponto de vista estratégico de negócios.

Relação entre Features e Target: Através do treinamento preliminar de um modelo *Random Forest Regressor* para extração de importância, identificou-se que as variáveis preditoras dominantes são *Original_Price* (aprox. 76% de importância), *Quantity* (19%) e *Discount_Percent* (3,6%). Após a remoção de variáveis altamente correlacionadas e redundantes (como *Order_Value* e *Selling_Price*) para evitar o vazamento de dados (*data leakage*), o modelo confirmou que a combinação de preço original, quantidade e descontos explica quase a totalidade da variância do valor final. Atributos físicos do produto (peso) ou demográficos (idade) demonstraram poder preditivo quase nulo para esta finalidade financeira.

Percepções e Recomendações para Modelagem:

- **Principais features recomendadas:** *Original_Price*, *Quantity* e *Discount_Percent*.
- **Desafios:** O principal desafio é evitar a multicolinearidade e o *data leakage* ao isolar variáveis diretamente derivadas do preço. Outro ponto de atenção é capturar possíveis interações não lineares entre grandes volumes de compra e as faixas de desconto.

-
- **Sugestões de algoritmos:** Recomenda-se testar inicialmente uma *Regressão Linear Múltipla* como linha de base (*baseline*), seguida por algoritmos baseados em árvores, como *Random Forest Regressor* ou *XGBoost*, para capturar padrões matemáticos mais complexos.

4.2 Problema de Classificação

Identificação da Variável Alvo (Target): Propôs-se a criação de uma variável categórica binária denominada *Usou_Cupom*, derivada da coluna *Coupon_Code* (onde 0 = "Sem_Cupom" e 1 = "Usou Cupom").

Justificativa: A capacidade de prever se um cliente está propenso a utilizar um cupom promocional permite que a equipe de marketing direcione campanhas de forma inteligente e personalizada, evitando a distribuição desnecessária de descontos para clientes que já comprariam organicamente. O critério de discretização foi o isolamento da *string* de ausência (Sem_Cupom) estabelecida previamente na etapa de limpeza de dados.

Relação entre Features e Target: A análise de extração de características via *Random Forest Classifier* demonstrou uma distribuição saudável de importância, sem indícios de vazamento de dados. As variáveis preditoras mais determinantes para o uso de cupons foram o *Total_Amount* (aprox. 25% de importância), seguido pelo *Pincode* (CEP) e pelo *Total_Spent* (ambos com aprox. 9% de importância). Esses resultados indicam que o comportamento promocional da loja está fortemente atrelado ao valor financeiro do carrinho (possivelmente devido a regras de gasto mínimo), à localização geográfica do cliente (sugerindo campanhas de marketing regionalizadas) e ao histórico de fidelidade do consumidor. O vazamento de dados foi rigorosamente evitado removendo-se o atributo *Coupon_Discount*.

Percepções e Recomendações para Modelagem:

- **Principais features recomendadas:** *Total_Amount*, *Pincode*, *Total_Spent*, *Order_Value* e *Customer_Age*.
- **Desafios:** O desafio central para este problema é o **desbalanceamento de classes**, visto que a maioria absoluta da base de dados não utiliza cupons, o que pode enviesar o modelo a prever sempre a classe majoritária.
- **Sugestões de algoritmos:** Recomenda-se treinar algoritmos como *Regressão Logística* (utilizando penalidade e ajuste de pesos para classes minoritárias) e *Random Forest Classifier*. Adicionalmente, será indispensável a aplicação de técnicas de balanceamento de dados, como o SMOTE, antes do treinamento final.

5 Considerações Finais

A execução deste trabalho prático evidenciou a complexidade e a importância crítica da etapa de Análise Exploratória e Pré-processamento no fluxo de desenvolvimento de modelos de *Machine Learning*. Ao longo do processo, ficou claro que a preparação dos dados vai muito além da simples execução de funções de código; ela exige uma interpretação analítica alinhada às regras de negócio e ao domínio do problema.

Dentre os principais **aprendizados**, destaca-se a mudança de perspectiva em relação aos dados ausentes e aos valores atípicos (*outliers*). Compreendeu-se que forçar preenchimentos estatísticos padronizados (como médias ou zeros) pode corromper indicadores reais da loja. A decisão de transformar vazios em novas categorias textuais (no caso de cupons e avaliações) demonstrou ser uma estratégia analítica superior. Além disso, a manutenção dos *outliers* provou ser essencial para não cegar o modelo diante de comportamentos estatisticamente minoritários, mas financeiramente legítimos, como compras corporativas de alto volume e políticas de frete grátis.

Quanto às **dificuldades** enfrentadas, o principal desafio técnico residiu na adequação estrutural da base às exigências puramente matemáticas dos algoritmos. Ferramentas preditivas não toleram valores nulos ou identificadores de texto (como códigos de pedido), exigindo uma limpeza rigorosa e a aplicação de técnicas de *One-Hot Encoding* e padronização. Outro obstáculo superado foi a mitigação do vazamento de dados (*data leakage*) e da multicolinearidade. Observou-se, na prática, como variáveis intrinsecamente derivadas do alvo podem fornecer a "resposta" de forma antecipada ao algoritmo, gerando métricas irreais de acerto que só foram corrigidas através de testes iterativos e seleção rigorosa de *features*.

Em suma, a atividade consolidou a premissa de que a eficácia e a confiabilidade de um modelo preditivo de Inteligência Artificial são reflexos diretos da qualidade, limpeza e interpretação crítica da base de dados que o alimenta.

6 Referência ao Repósitorio

Todo o código desenvolvido, os blocos de script, os conjuntos de dados processados e os arquivos deste relatório estão publicamente versionados e disponíveis em um repositório no GitHub. A estrutura do projeto foi organizada de maneira modular para garantir a reprodutibilidade de todas as etapas de Análise Exploratória e Machine Learning.

O link de acesso ao repositório oficial do projeto é:

`https://github.com/seu-usuario/nome-do-repositorio`

A organização interna dos diretórios e arquivos do repositório segue a seguinte estrutura:

- **data/**: Contém dentro do diretório `raw/` o dataset original e no diretório `processed` a base tratada e limpa (`dataset_clean.csv`) pronta para ser consumida pelos modelos preditivos.
- **notebooks/**: Agrupa os arquivos em Jupyter Notebook estruturados em etapas sequenciais:
 - `01_eda.ipynb.ipynb`: Levantamento inicial dos dados.
 - `02_preprocessing.ipynb`: Limpeza, tratamento de nulos, variáveis categóricas e padronização.
 - `03_regression_analysis.ipynb`: Seleção de features, treino e avaliação do modelo de regressão.
 - `04_classification_analysis.ipynb`: Criação do target, testes e avaliação do modelo de classificação.
- **reports/**: Armazena os ativos visuais gerados pelas análises em `reports/figures/` (matriz de correlação, gráficos de importância de features, *boxplots* de outliers).
- **docs/**: Contém uma cópia do relatório final em pdf.