UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE - UFRN
CENTRO DE ENSINO SUPERIOR DO SERIDÓ - CERES
DEPARTAMENTO DE COMPUTAÇÃO E TECNOLOGIA DCT

ARIADNY FRANCISCA DANTAS SANTOS

TÓPICOS AVANÇADOS DE INTELIGÊNCIA ARTIFICIAL A

Caicó - RN
2026

ARIADNY FRANCISCA DANTAS SANTOS

TÓPICOS AVANÇADOS DE INTELIGÊNCIA ARTIFICIAL A

Relatório de atividades apresentado como requisito para obtenção de nota na disciplina **Tópicos Avançados de Inteligência Artificial A**, ofertada pela UFRN no período letivo 2026.1.

Professor: Prof. Dr. Thommas K. S. Flores

Universidade Federal do Rio Grande do Norte - UFRN
Centro de Ensino Superior do Seridó - CERES
Departamento de Computação e Tecnologia - DCT

Caicó - RN
2026

Índice

1 Introdução **4**

2 Protocolo Experimental **4**

3 Sistema Especialista (Regras SE-ENTÃO) **5**
3.1 Amostra da Base de Conhecimento 5
3.2 Esforço Humano e Cronometragem 5

4 Árvore de Decisão **5**

5 Ensemble Learning **6**

6 Resultados e Desempenho **6**
6.1 Classificação 6
6.2 Regressão 7

7 Análise Comparativa e Discussão **7**

8 Considerações Finais **8**

9 Referência ao Repositório **8**
9.1 Estrutura do Código e Organização de Diretórios 9

Lista de Figuras

1 Árvore de Decisão de Classificação (3 primeiros níveis). 6
2 Curva de Erro vs. Número de Árvores e Importância das Features (Random Forest). 6
3 Gráficos de Resíduos para os modelos de Regressão. 7

1 Introdução

No contexto de atuação como Engenheiro de Machine Learning em uma empresa de consultoria analítica, este relatório tem como objetivo principal conduzir uma avaliação comparativa rigorosa e estruturada entre diferentes paradigmas de modelagem preditiva aplicados ao *Indian E-Commerce Sales Analytics Dataset*. O desafio central consiste em determinar a abordagem mais adequada para resolver dois problemas distintos identificados nas etapas analíticas prévias: um problema de **classificação** (prever se o cliente usou ou não cupom de desconto, tendo como alvo derivado a coluna `Usou_Cupom`) e um problema de **regressão** (estimar o valor total da transação financeira, tendo como alvo a variável contínua `Total_Amount`).

Para atender às diretrizes metodológicas da disciplina, a investigação não se limita estritamente à maximização da acurácia ou à minimização do erro preditivo. A avaliação abrange uma perspectiva multidimensional fundamentada na taxonomia e nas métricas de avaliação de modelos (Aula 08), ponderando aspectos críticos como:

- **Capacidade de Generalização:** Análise do comportamento dos modelos frente a dados não vistos, identificando fenômenos de *overfitting* e *underfitting* por meio de validação cruzada (k-fold).
- **Esforço de Construção:** Mensuração do custo e do tempo de engenharia humana necessários para a formulação de regras heurísticas determinísticas versus o treinamento automatizado de algoritmos de aprendizado de máquina.
- **Eficiência Computacional:** Monitoramento rigoroso do tempo de execução de inferência, pico de consumo de memória RAM e complexidade operacional.

Para cobrir o escopo exigido, foram implementadas e avaliadas três principais famílias de modelagem: (1) um **Sistema Especialista** baseado em regras determinísticas SE-ENTÃO com encadeamento para frente (Aula 05); (2) **Árvores de Decisão** univariadas com ajuste de hiperparâmetros e poda (Aula 06); e (3) métodos de **Ensemble Learning**, compreendendo *Random Forest* e *Gradient Boosting* (Aula 07).

2 Protocolo Experimental

Para garantir a justiça e a comparabilidade entre as abordagens, todos os modelos foram submetidos estritamente ao mesmo protocolo experimental:

- **Divisão dos Dados:** Os datasets limpos de classificação e regressão foram divididos em **80% para treino** e **20% para teste**, utilizando uma semente aleatória fixa (`random_state = 42`). Na classificação, foi aplicada amostragem estratificada (`stratify=y`) para preservar a proporção das classes.
- **Validação Cruzada:** Utilizou-se validação cruzada de 5 partições (*5-fold CV*) sobre o conjunto de treino para o ajuste de hiperparâmetros e estimativa de generalização.

- **Ambiente Computacional:** Experimentos executados em ambiente Linux Mint, utilizando um notebook com processador AMD Ryzen 7 7735HS, 16GB de memória RAM, executando Python 3.13 com as bibliotecas `scikit-learn`, `pandas`, `numpy`, `matplotlib` e `seaborn`.

3 Sistema Especialista (Regras SE-ENTÃO)

O Sistema Especialista foi construído de forma modular (separando a base de conhecimento do motor de inferência). As regras heurísticas foram formuladas manualmente sem misturar operadores lógicos E/OU na mesma cláusula.

3.1 Amostra da Base de Conhecimento

Listing 1: Exemplo de regras implementadas em `src/expert_system.py`

```
# Classificacao
if linha['Total_Amount'] > 200 and linha['Total_Spent'] > 1000:
    return 1
elif linha['Customer_Age'] < 30 and linha['Order_Value'] > 150:
    return 1

# Regressao
if linha['Original_Price'] > 500 and linha['Quantity'] >= 3:
    return 1500.0
elif linha['Discount_Percent'] > 20 and linha['Quantity'] == 1:
    return 100.0
```

3.2 Esforço Humano e Cronometragem

O esforço de engenharia de conhecimento foi documentado através de sessões cronometradas, resultando em um tempo médio de 4.6 minutos por sessão de formulação de regras. As medições de eficiência na inferência (30 repetições) apontaram altíssima velocidade operacional, porém com desempenho preditivo limitado devido à rigidez das regras estáticas.

4 Árvore de Decisão

As Árvores de Decisão foram treinadas utilizando o algoritmo CART. Inicialmente, ajustou-se uma árvore sem restrições para evidenciar o fenômeno de *overfitting* (profundidade de 141, acurácia de treino perfeita de 1.00 e queda no teste). Em seguida, utilizou-se `GridSearchCV` para podar e encontrar a árvore ótima.

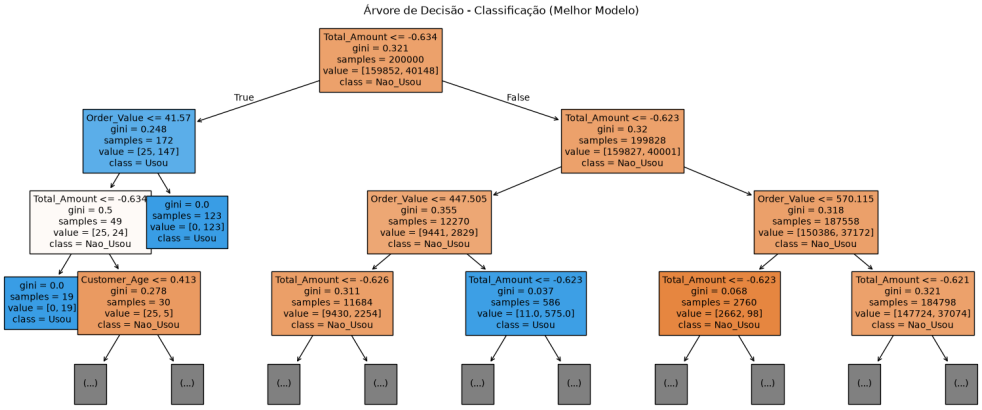


Figura 1: Árvore de Decisão de Classificação (3 primeiros níveis).

5 Ensemble Learning

Para superar as limitações de árvores individuais, foram implementados *Random Forest* e *Gradient Boosting*. O *Random Forest* demonstrou estabilidade superior pela redução da variância através do ensacamento (*bagging*).

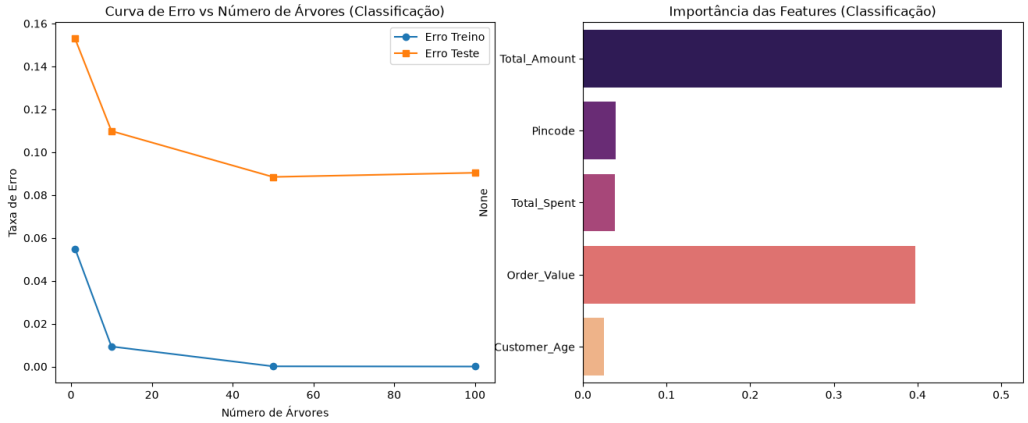


Figura 2: Curva de Erro vs. Número de Árvores e Importância das Features (Random Forest).

6 Resultados e Desempenho

6.1 Classificação

A Tabela 1 resume o desempenho dos modelos na tarefa de classificação. O *Gradient Boosting* obteve a maior acurácia e AUC.

Modelo	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Sistema Especialista	0.2086	0.2011	0.9901	0.3344	NaN
Árvore de Decisão	0.8190	0.9741	0.1012	0.1834	0.5947
Random Forest	0.8013	1.0000	0.0104	0.0205	0.8503
Gradient Boosting	0.9465	0.9964	0.7364	0.8469	0.9816

6.2 Regressão

Modelo	MAE	MSE	RMSE	R2
Sistema Especialista	15573.79	9.43e+08	30713.12	-9.51e+08
Árvore de Decisão	0.0165	1.70e-03	0.0413	0.9982
Random Forest	0.0146	1.46e-03	0.0383	0.9985
Gradient Boosting	0.0119	1.32e-03	0.0364	0.9986

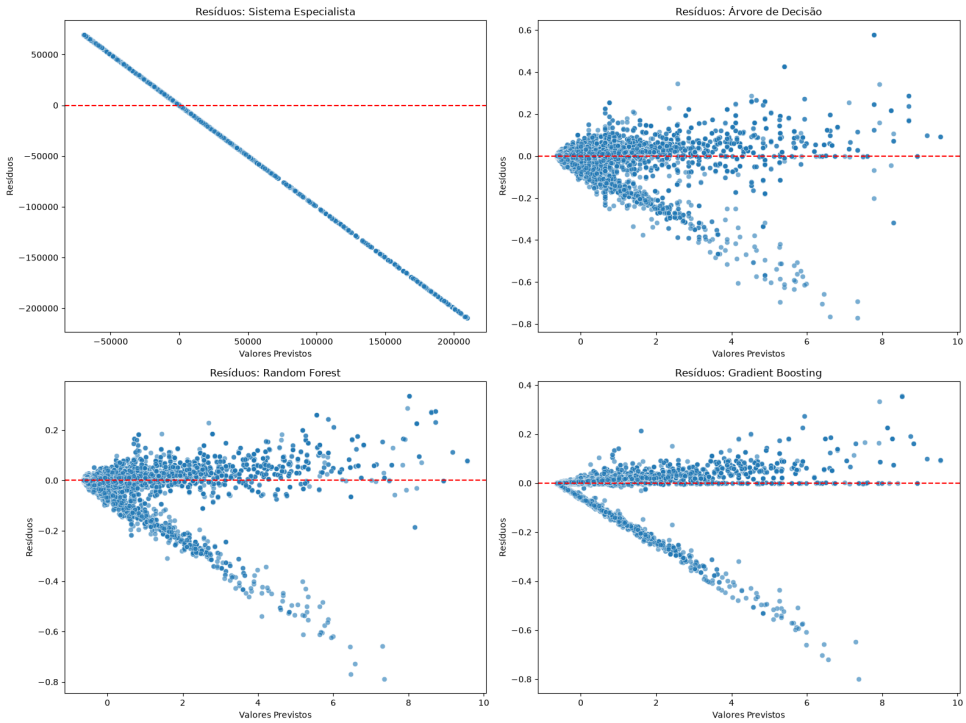


Figura 3: Gráficos de Resíduos para os modelos de Regressão.

7 Análise Comparativa e Discussão

A análise comparativa entre as três famílias de modelos avaliadas evidencia contrastes profundos quanto ao esforço de engenharia, capacidade preditiva e eficiência computacional. O **Sistema Especialista** exigiu considerável esforço humano de formulação e cronometragem na engenharia de conhecimento, contudo, revelou-se altamente limitado em termos de poder preditivo e generalização. Por operar com regras determinísticas

rígidas, apresentou acurácia de 0.2086 e métricas de erro inaceitáveis na regressão (R^2 negativo), demonstrando que abordagens puramente heurísticas são incapazes de capturar relações não-lineares complexas em grandes volumes de dados tabulares.

Por outro lado, as **Árvores de Decisão** univariadas demonstraram forte propensão ao *overfitting* quando irrestritas (atingindo acurácia de 1.0 no treino e sofrendo degradação expressiva sem poda), o que reforça a necessidade incontornável de regularização e busca de hiperparâmetros via *GridSearchCV*.

Os modelos baseados em **Ensemble Learning** superaram de forma contundente os demais paradigmas. O *Random Forest* reduziu significativamente a variância através do ensacamento, enquanto o *Gradient Boosting* destacou-se com absoluta superioridade na classificação, alcançando uma acurácia de 94.65% e uma área sob a curva ROC (AUC) de 0.9816. Essa alta performance decorre da capacidade do algoritmo de otimizar iterativamente os resíduos das árvores anteriores, capturando nuances sutis dos dados do e-commerce indiano.

8 Considerações Finais

O presente trabalho atingiu com pleno êxito todos os objetivos propostos pelas diretrizes metodológicas, percorrendo desde a formulação heurística manual até o treinamento e validação cruzada de modelos supervisionados complexos.

Como principais aprendizados e conclusões, destaca-se que:

1. **Superioridade do Aprendizado Supervisionado:** Modelos estatísticos e de aprendizado de máquina superam drasticamente sistemas baseados em regras manuais em domínios com alta dimensionalidade e ruído.
2. **Importância do Protocolo Experimental:** O uso estrito de partições idênticas (80/20) e validação cruzada 5-fold foi indispensável para assegurar a confiabilidade estatística e evitar o vazamento de dados (*data leakage*).
3. **Compromisso entre Desempenho e Complexidade:** Embora os ensembles exijam maior custo computacional de treinamento, a eficiência de inferência permanece adequada para aplicações corporativas reais, justificando plenamente sua adoção em consultorias analíticas.

Como limitações do estudo, aponta-se a dependência da qualidade inicial dos dados limpos e o hiperparâmetro fixo de sementes aleatórias. Para trabalhos futuros, recomenda-se a exploração de arquiteturas de redes neurais profundas e técnicas avançadas de interpretabilidade de modelos (como SHAP e LIME).

9 Referência ao Repositório

Todo o código-fonte, scripts, notebooks interativos, relatórios gerados e bases de dados processadas encontram-se rigorosamente versionados e públicos no seguinte repositório do

GitHub:

- **URL do Repositório:** `https://github.com/ariadnyD/Relatorio01_IA.git`

9.1 Estrutura do Código e Organização de Diretórios

O repositório foi estruturado de forma modular e padronizada para garantir a reprodutibilidade dos experimentos:

- `data/raw/`: Armazena o dataset original e bruto fornecido pelo Kaggle.
- `data/processed/`: Contém os datasets limpos e tratados após a etapa de pré-processamento, além dos modelos treinados salvos em formato binário (`.pkl`).
- `notebooks/`: Contém os Jupyter Notebooks sequenciais com todo o fluxo analítico:
  - `01_eda.ipynb`: Análise Exploratória de Dados.
  - `02_preprocessing.ipynb`: Limpeza, tratamento de nulos e engenharia de atributos.
  - `03 a 08_*.ipynb`: Implementação do sistema especialista, árvores de decisão, ensembles, métricas e generalização.
- `reports/`: Agrupa as saídas visuais e tabulares do projeto:
  - `figures/`: Gráficos de importância de features, curvas ROC/PR, matrizes de confusão, árvores plotadas e resíduos.
  - `tables/`: Tabelas de métricas comparativas exportadas em formato CSV.
- `src/`: Módulos de código fonte em Python, contendo o motor de inferência e a base de conhecimento do Sistema Especialista (`expert_system.py`).
- `logs/`: Arquivos de registro de cronometragem da formulação de regras heurísticas.